矩阵的秩

矩阵的秩等于其列向量组中线性无关向量的最大个数，也等于行向量组中线性无关向量的最大个数。求矩阵的秩，可以进行初等行变换，把矩阵化为阶梯形，再数非零行。秩描述了矩阵中独立信息的数量。例如三列向量中只有两列独立，其余一列是前两列的线性组合，则矩阵的秩为二。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

线性方程组

线性方程组　$Ax=b$

的可解性可以通过系数矩阵与增广矩阵的秩判断。当二者的秩不相等时无解。当二者的秩相等且等于未知数个数时，有唯一解。当二者的秩相等但小于未知数个数时，有无穷多解。对齐次方程组

$Ax=0$，零解总是存在；有非零解的条件是系数矩阵的秩小于未知数个数。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

特征值与特征向量

若方阵 A 与非零向量 v 满足 $Av=\lambda v$，则 λ 称为特征值，v 称为对应的特征向量。矩阵作用于这个方向后，结果仍在同一条直线上，只发生伸缩或反向。特征值可以通过特征方程 $\det(A-\lambda I)=0$ 求得。特征向量不能是零向量，否则任意 λ 都满足等式，无法表达特殊方向。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

奇异值分解

奇异值分解将矩阵写成 $U\Sigma V$ 的转置乘积，其中 U、V 为正交矩阵，Σ 的对角线上是非负奇异值。只保留最大的 k 个奇异值及对应向量，可以获得低秩近似。图像可看作像素矩阵，因此低秩近似可用于图像压缩。保留越多奇异值，通常重建误差越小，但需要存储的参数越多。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

导数与梯度

导数刻画一元函数在某点附近的瞬时变化率。在多元函数中，将各变量的偏导数排列起来形成梯度向量。梯度指向函数值局部增长最快的方向；负梯度是局部下降最快的方向。梯度为零的点是驻点，但驻点可能是极小值、极大值或鞍点，不能仅凭梯度为零判断找到最小值。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

梯度下降与学习率

梯度下降通过反复沿负梯度方向更新参数来降低损失。更新公式为新参数等于旧参数减去学习率乘以当前梯度。学习率控制每次更新的步长。学习率过大会导致振荡甚至发散，过小则收敛缓慢。实践中可以观察训练损失曲线，调整学习率，或采用随训练逐渐减小的学习率。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

条件概率与贝叶斯公式

条件概率 P（A｜B） 表示在事件 B 已发生时 A 发生的概率，要求 P（B）> 0。贝叶斯公式为 P（A｜B）= P（B｜A）P（A）/ P（B）。其中 P（A） 是先验概率，P（A｜B） 是观察证据之后的后验概率。即便某检测方法较准确，当目标事件本身非常罕见时，阳性结果也不一定意味着目标事件很可能发生。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

期望与方差

数学期望描述随机变量的平均水平，离散随机变量的期望是各取值与对应概率乘积之和。方差描述取值围绕期望的波动程度，等于偏差平方的期望。标准差是方差的平方根，与原变量具有相同的单位。两个随机变量期望相同，并不代表它们的波动程度相同。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

训练集、验证集与测试集

训练集用于拟合模型参数。验证集用于选择超参数和比较候选模型。测试集用于在最终方案确定后评估泛化表现。不能依据测试集结果反复选择模型，否则测试信息间接参与开发。预处理中的均值、方差等统计量也应仅从训练集估计，再应用于验证集和测试集，避免数据泄漏。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

过拟合与正则化

过拟合指模型过度适应训练数据中的细节或噪声，在训练集上表现好，在未见数据上表现差。常见信号是训练损失持续下降，而验证损失开始上升。缓解方法包括增加训练数据、减少模型复杂度、加入正则化和使用早停。正则化通过惩罚过大的参数等方式限制复杂度；早停根据验证表现停止训练。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

特征标准化

特征标准化通常把每个特征减去训练集均值，再除以训练集标准差。不同特征量纲差异很大时，距离计算或梯度优化可能被数值尺度大的特征主导。标准化可以改善某些模型的优化过程和特征可比性。对于标准差为零的常量特征，应专门处理，避免除以零。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

分类评估与混淆矩阵

混淆矩阵按真实类别与预测类别统计数量，可用于发现模型容易混淆的类别。准确率是预测正确的样本占全部样本的比例。精确率是预测为正的样本中实际为正的比例，召回率是实际为正的样本中被成功找出的比例。类别不平衡时只看准确率可能误导，应结合精确率、召回率和具体错误案例。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

ＴＦ－ＩＤＦ　文本表示

ＴＦ－ＩＤＦ

将词频与逆文档频率结合，用于表示词语对文档的重要性。一个词在某段落频繁出现、但在整个语料中较少出现，往往具有较高区分度。检索时把段落和查询转换为同一词表下的向量，再比较相似程度。ＴＦ－ＩＤＦ

依赖词语重合，不能可靠理解同义改写或复杂推理。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

余弦相似度

余弦相似度等于两个向量内积除以两者长度的乘积，用于衡量方向的接近程度。对于经过 L2 归一化的向量，余弦相似度就是内积。文本检索中，它可以比较查询与段落的词语权重分布。该分数不是概率，也不代表答案正确率。全零查询向量表示查询没有命中词表，应返回无结果。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

向量化与性能测量

向量化把逐元素的 Ｐｙｔｈｏｎ 循环改为数组级运算，通常能调用优化过的底层计算实现。比较性能时应先检查数值结果一致，再进行预热和多次重复计时，报告中位数或分布。计时范围必须说明是否包含数据准备与传输。一次很快的运行不足以证明稳定加速，不同数据规模可能产生不同结论。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。

广度优先搜索与 A 星算法

广度优先搜索按距离起点的层数逐层访问节点，在无权图中可求最少边数的路径。A 星算法结合已经付出的路径代价和到目标的启发式估计。启发式函数若不高估剩余代价，并正确处理节点更新等条件，可以保证最优路径。比较寻路算法时，除了路径长度，还应统计访问节点数和耗时。

自编演示资料，仅用于项目功能和检索实验，不替代正式教材。